



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Actividad Práctica – Semana 3

DISEÑA UNA ARQUITECTURA DE DATOS

Isabella Ramos Betancourt

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel Gonzáles Bonilla

Agosto 30 de 2026



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"




1. Introducción

El análisis de datos en procesos agroindustriales no depende únicamente de la calidad de la información disponible, sino también de la infraestructura tecnológica que permite recolectarla, almacenarla, procesarla y convertirla en decisiones operativas. Una arquitectura de datos mal diseñada puede generar cuellos de botella, pérdida de información o tiempos de respuesta inadecuados para las necesidades del proceso. Por esta razón, definir el flujo de datos desde las fuentes hasta el análisis constituye una etapa fundamental en cualquier proyecto de ciencia de datos aplicado al entorno agroindustrial.

Este trabajo propone una arquitectura de datos para el proyecto de producción agroindustrial con enfoque en la gestión del riego, que integra las fuentes identificadas en el encuadre del proyecto —sensores de humedad del suelo, temperatura, consumo de agua, precipitación, etapa de crecimiento, rendimiento de cosechas y registros históricos de riego— en un flujo coherente que abarca las etapas de ingesta, almacenamiento, procesamiento y análisis. Se justifica la elección de un Data Lake frente a un Data Warehouse, así como el uso de una arquitectura predominantemente por lotes adecuada para las decisiones de programación del riego. Adicionalmente, se propone una herramienta candidata para cada etapa del flujo, argumentando su pertinencia en el contexto del caso.

2. Desarrollo de la actividad

2.1. Arquitectura del flujo de datos






CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

4.



Sede Quirinal: Calle 21 No. 6 - 01

Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989

NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



2.2 Justificación de las decisiones de arquitectura

¿Data Lake o Data Warehouse?

Para este proyecto se opta por un **Data Lake**. La razón principal es la variedad de las fuentes de datos identificadas en el encuadre del proyecto: los sensores de humedad del suelo, temperatura, consumo de agua y precipitación generan datos numéricos estructurados, pero el proyecto también incorpora registros históricos de riego y producción en formatos semiestructurados, así como informes técnicos de campo en texto libre. Un Data Warehouse solo admite datos ya transformados y con esquema definido, lo que obligaría a descartar información valiosa —como las observaciones cualitativas de los técnicos— antes de siquiera explorarla.

El Data Lake permite almacenar todas las fuentes en su formato original (zona cruda) y aplicar transformaciones de forma posterior según las necesidades del análisis, siguiendo el principio de *schema-on-read*. Adicionalmente, resulta más escalable para el volumen de datos que generan los sensores durante múltiples ciclos de producción.

¿Batch o Streaming?

El proyecto requiere una **arquitectura predominantemente batch**. La FAO (2026) muestra que las herramientas de gestión del riego trabajan típicamente con análisis de series temporales sobre datos acumulados por semana o por ciclo de cultivo. La decisión planteada —mejorar la programación del riego— no requiere respuesta en milisegundos: se puede recopilar la información

de humedad, temperatura, precipitación y rendimiento durante un período determinado y analizarla para ajustar la estrategia en los ciclos siguientes.

Sin embargo, se incorpora un componente de **streaming ligero** únicamente para detectar caídas bruscas y sostenidas en los datos de humedad del suelo durante períodos de alta temperatura, de modo que se genere una alerta operativa oportuna sin necesidad de esperar al procesamiento semanal. El grueso del análisis descriptivo e histórico se realiza en modo batch.

2.3. Herramientas candidatas por etapa

Etapas	Herramientas	Justificación
Ingesta	Apache NiFi	NiFi es una plataforma de gestión de flujos de datos con interfaz visual que permite diseñar, monitorear y controlar el movimiento de información desde múltiples fuentes hacia el almacenamiento. Es adecuada para integrar datos de sensores de humedad, temperatura y precipitación junto con los registros históricos de riego, cosechas y etapa de crecimiento, de forma automatizada y con control de calidad en cada paso. Para el componente de alertas de humedad crítica en tiempo real, Apache Kafka complementa esta etapa.



Procesamiento	Apache Spark	Spark permite procesar grandes volúmenes de datos en modo batch de forma distribuida. Sus capacidades de transformación, limpieza e integración hacen posible consolidar los datos de humedad del suelo, temperatura, consumo de agua, precipitación, etapa de crecimiento y rendimiento de cosechas de múltiples ciclos de producción, preparando los conjuntos de datos que alimentarán el análisis descriptivo (Apache Software Foundation, 2024).
Análisis/BI	Power BI	Power BI permite crear dashboards interactivos que visualizan el estado de los equipos, las alertas de falla y el historial de mantenimiento de forma accesible para los operarios y gestores de planta. Se integra con fuentes de datos en la nube y soporta actualización automática, lo que facilita la toma de decisiones operativas en tiempo real (Microsoft, 2024).



3. Conclusión

La arquitectura propuesta demuestra que el proyecto de producción agroindustrial con gestión de riego requiere una infraestructura flexible y escalable, capaz de integrar las variables definidas en el encuadre del proyecto —humedad del suelo, temperatura, consumo de agua, precipitación, etapa de crecimiento, rendimiento de cosechas y registros históricos de riego— en un flujo coherente que va desde la captura hasta la toma de decisiones. La elección del Data Lake como capa de almacenamiento responde a la variedad inherente del caso: conservar los datos en su formato original permite explorarlos sin imponer un esquema rígido desde el inicio, lo que resulta especialmente valioso en etapas tempranas del proyecto.

La arquitectura predominantemente batch refleja una necesidad real del entorno agrícola: las decisiones sobre programación del riego se toman con base en el comportamiento acumulado del cultivo durante días o semanas, no en segundos. Las herramientas seleccionadas —NiFi, Apache Spark y Power BI— ofrecen la integración necesaria para soportar cada etapa del flujo. En conjunto, esta arquitectura establece las bases tecnológicas sobre las cuales puede construirse el sistema de análisis del riego de manera robusta y sostenible.



4. Referencias

Apache Software Foundation. (2024). Apache Spark overview.

<https://spark.apache.org/docs/latest/>

Food and Agriculture Organization of the United Nations. (2026). Water data and resource assessment. <https://www.fao.org/land-water/water/water-data-and-resource-assessment>

Food and Agriculture Organization of the United Nations. (2026). Tools in co-development: WaPOR, remote sensing for water productivity. <https://www.fao.org/in-action/remote-sensing-for-water-productivity/country-activities/tools-in-co-development>

IBM. (2024). What is Big Data analytics? IBM Think. <https://www.ibm.com/think/topics/big-data-analytics>

Microsoft. (2024). ¿Qué es Power BI? <https://learn.microsoft.com/es-es/power-bi/fundamentals/power-bi-overview>

