



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Actividad Práctica – Semana 3

DISEÑA UNA ARQUITECTURA DE DATOS

Isabella Ramos Betancourt

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel Gonzáles Bonilla

Agosto 30 de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



1. Introducción


El análisis de datos en procesos industriales no depende únicamente de la calidad de la información disponible, sino también de la infraestructura tecnológica que permite recolectarla, almacenarla, procesarla y convertirla en decisiones operativas. Una arquitectura de datos mal diseñada puede generar cuellos de botella, pérdida de información o tiempos de respuesta inadecuados para las necesidades del negocio. Por esta razón, definir el flujo de datos desde las fuentes hasta el análisis constituye una etapa fundamental en cualquier proyecto de ciencia de datos aplicado al entorno industrial.

Este trabajo propone una arquitectura de datos para el proyecto de mantenimiento predictivo de equipos industriales, que integra múltiples fuentes heterogéneas —sensores IoT, registros históricos de fallas e informes técnicos— en un flujo coherente que abarca las etapas de ingesta, almacenamiento, procesamiento y análisis. Se justifica la elección de un Data Lake frente a un Data Warehouse, así como el uso de una arquitectura mixta que combina procesamiento en streaming para los datos de sensores en tiempo real y procesamiento por lotes para la información histórica. Adicionalmente, se propone una herramienta candidata para cada etapa del flujo, argumentando su pertinencia en el contexto del caso.



2. Desarrollo de la actividad

2.1. Arquitectura del flujo de datos



📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

4.



📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989

NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"

2.2 Justificación de las decisiones de arquitectura

¿Data Lake o Data Warehouse?

Para este proyecto se opta por un **Data Lake**. La razón principal es la variedad de los datos que deben almacenarse: los sensores generan datos numéricos estructurados en alta frecuencia, pero el proyecto también incorpora informes técnicos en texto libre y registros de mantenimiento en formatos semiestructurados. Un Data Warehouse solo admite datos ya transformados y con esquema definido, lo que obligaría a descartar información valiosa antes de siquiera explorarla. El Data Lake permite almacenar todos los datos en su formato original (zona cruda) y aplicar transformaciones de forma posterior según las necesidades del análisis, siguiendo el principio de *schema-on-read*.

Adicionalmente, el Data Lake resulta más escalable y económico para el volumen de datos que generan múltiples sensores durante largos períodos de operación.

¿Batch o Streaming?

El proyecto requiere una **arquitectura mixta**:

- ✓ **Streaming** para los datos de sensores en tiempo real (temperatura, vibración, presión, corriente). La detección temprana de señales de degradación exige que los datos se procesen casi de forma inmediata. Una arquitectura solo batch, que procesa datos en ventanas de horas o días, sería insuficiente para emitir alertas oportunas.

- ✓ **Batch** para el procesamiento de datos históricos (historial de fallas, órdenes de mantenimiento, informes técnicos). Este tipo de información no requiere procesamiento inmediato; se puede consolidar, limpiar y enriquecer de forma periódica para reentrenar los modelos predictivos o actualizar los dashboards de tendencia.

2.3. Herramientas candidatas por etapa

Etapas	Herramientas	Justificación
Ingesta	Apache Kafka	Kafka es una plataforma de mensajería distribuida diseñada para el procesamiento de flujos de datos en tiempo real con alta disponibilidad y baja latencia. Es ampliamente utilizada en arquitecturas industriales de IoT para recibir y enrutar los datos de sensores hacia el almacenamiento o el procesamiento (Confluent, 2024). Para datos históricos o por lotes, Apache NiFi complementa esta etapa con capacidades de ETL visual y gestión de flujos de datos.
Procesamiento	Apache Spark	Spark permite procesar grandes volúmenes de datos tanto en modo batch como en streaming (Spark Structured Streaming). Su capacidad de ejecutar transformaciones distribuidas y sus bibliotecas de Machine Learning integradas (MLlib) lo hacen adecuado para la ingeniería de características y el



		entrenamiento del modelo de predicción de fallas (Apache Software Foundation, 2024).
Análisis/BI	Power BI	Power BI permite crear dashboards interactivos que visualizan el estado de los equipos, las alertas de falla y el historial de mantenimiento de forma accesible para los operarios y gestores de planta. Se integra con fuentes de datos en la nube y soporta actualización automática, lo que facilita la toma de decisiones operativas en tiempo real (Microsoft, 2024).



3. Conclusión

La arquitectura propuesta demuestra que el proyecto de mantenimiento predictivo requiere una infraestructura flexible y escalable, capaz de integrar fuentes de datos con características muy distintas en un flujo coherente que va desde la captura hasta la toma de decisiones. La elección del Data Lake como capa de almacenamiento responde a la variedad inherente del caso: conservar los datos en su formato original permite explorarlos sin imponer un esquema rígido desde el inicio, lo que resulta especialmente valioso en etapas tempranas del proyecto donde los requisitos del modelo predictivo aún pueden evolucionar.

La combinación de procesamiento en streaming y por lotes refleja una necesidad real del entorno industrial: las alertas de falla deben generarse en tiempo real a partir de los datos de sensores, mientras que el reentrenamiento de los modelos y la consolidación del historial pueden realizarse de forma periódica sin comprometer la operación. Las herramientas seleccionadas —Kafka, Apache Spark y Power BI— cuentan con respaldo amplio en implementaciones industriales similares y ofrecen la integración necesaria para soportar cada etapa del flujo. En conjunto, esta arquitectura establece las bases tecnológicas sobre las cuales puede construirse el sistema de mantenimiento predictivo de manera robusta y sostenible.





4. Referencias

Apache Software Foundation. (2024). *Apache Spark overview*.

<https://spark.apache.org/docs/latest/>

Confluent. (2024). *What is Apache Kafka?* <https://www.confluent.io/what-is-apache-kafka/>

IBM. (2024). *¿Qué es el análisis de big data?* IBM Think. <https://www.ibm.com/es-es/think/topics/big-data-analytics>

IBM. (2026). *¿Qué es el mantenimiento predictivo?* IBM Think. <https://www.ibm.com/es-es/think/topics/predictive-maintenance>

Microsoft. (2024). *¿Qué es Power BI?* <https://learn.microsoft.com/es-es/power-bi/fundamentals/power-bi-overview>