



Actividad Práctica – Semana 4

TIPOS DE ANALÍTICA Y ÉTICA

Isabella Ramos Betancourt

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel Gonzáles Bonilla

Agosto 30 de 2026





1. Introducción

La Ciencia de Datos no se limita a describir lo que ha ocurrido en un sistema; dependiendo del tipo de pregunta que se formule y de la profundidad del análisis, es posible diagnosticar causas, anticipar eventos futuros e incluso recomendar acciones concretas. Esta progresión —de lo descriptivo a lo prescriptivo— define los cuatro tipos de analítica que estructuran el pensamiento analítico moderno y que determinan qué clase de valor puede extraerse de los datos disponibles.

En el proyecto de producción agroindustrial con enfoque en la gestión del riego, cada tipo de analítica aporta una perspectiva distinta y complementaria sobre las variables del caso: humedad del suelo, temperatura, cantidad de agua utilizada por ciclo de riego, datos de precipitación, etapa de crecimiento del cultivo, rendimiento de cosecha y registros históricos de riego y producción. Este trabajo formula una pregunta representativa para cada tipo de analítica, justifica el uso de aprendizaje automático supervisado como enfoque principal para las etapas predictiva y prescriptiva, y analiza un sesgo ético concreto derivado de la calidad desigual de los registros históricos entre lotes, proponiendo estrategias específicas para mitigarlo.





2. Desarrollo de la actividad

2.1. Preguntas clasificadas por tipo de analítica

A continuación se formulan cuatro preguntas sobre el caso de producción agroindustrial y gestión del riego, una por cada tipo de analítica.

2.1.1. Analítica Descriptiva

¿Qué ha ocurrido?

¿Cuáles lotes registraron el mayor consumo de agua por ciclo de riego durante el último año y cuál fue el comportamiento promedio de la humedad del suelo, la temperatura y el rendimiento de cosecha asociados a esos períodos?

Esta pregunta busca caracterizar el historial de consumo hídrico y producción ya ocurridos, identificar patrones de comportamiento pasado y determinar qué lotes o períodos concentran mayor gasto de agua en relación con el rendimiento obtenido. Responde con estadísticas descriptivas, tablas de frecuencia, promedios por ciclo y gráficas de tendencia que integran las variables de humedad, temperatura y rendimiento.

2.1.2. Analítica Diagnóstica

¿Por qué ocurrió?



¿Qué combinación de variables —temperatura elevada, humedad del suelo baja, etapa de crecimiento avanzada y baja precipitación— está más asociada con los ciclos en que el consumo de agua fue alto y el rendimiento de la cosecha fue inferior al esperado?

Esta pregunta va más allá de describir el consumo, puesto que busca identificar las causas raíz de la ineficiencia hídrica mediante el análisis de correlaciones entre las variables del proceso (humedad, temperatura, precipitación, etapa de crecimiento) y los resultados de producción registrados históricamente. Permite entender por qué algunos ciclos de riego son ineficientes, no solo cuándo ocurrieron.

2.1.3. Analítica Predictiva

¿Qué podría ocurrir?

¿Con cuántos días de anticipación puede un modelo estimar la necesidad de riego de un lote a partir del comportamiento actual de los datos de humedad del suelo, temperatura y precipitación, considerando la etapa de crecimiento del cultivo?

Esta pregunta es el núcleo hacia el cual apunta el proyecto en su fase más avanzada. Busca construir un modelo que, con base en los patrones detectados en el análisis descriptivo y diagnóstico, estime la evolución de la humedad del suelo y anticipe la necesidad de riego antes de que el cultivo entre en estrés hídrico, optimizando el uso del agua por ciclo.



2.1.4. Analítica Prescriptiva

¿Qué se debe hacer?

Dado el estado actual de humedad del suelo, la temperatura, los datos de precipitación esperada y la etapa de crecimiento de cada lote, ¿cuál es el plan de riego óptimo para la próxima semana que maximice el rendimiento de la cosecha y minimice el consumo de agua?

Esta pregunta es el núcleo hacia el cual apunta el proyecto en su fase más avanzada. Busca construir un modelo que, con base en los patrones detectados en el análisis descriptivo y diagnóstico, estime la evolución de la humedad del suelo y anticipe la necesidad de riego antes de que el cultivo entre en estrés hídrico, optimizando el uso del agua por ciclo.

2.2. Tipo de ML para analítica predictiva y prescriptiva

Analítica Predictiva: ML Supervisado

Para responder la pregunta predictiva se utilizaría **aprendizaje automático supervisado**. La razón es que el proyecto cuenta con un historial de datos etiquetado: se conoce con exactitud en qué fechas se realizaron los riegos, cuál fue la humedad del suelo registrada, cuál fue la temperatura y la precipitación, en qué etapa de crecimiento estaba el cultivo y cuál fue el rendimiento de la cosecha resultante. Esto permite construir un conjunto de datos donde cada registro tiene asociada



una variable de salida conocida —la necesidad de riego o el nivel de humedad esperado—, que es exactamente la condición necesaria para entrenar un modelo supervisado.

Algoritmos como Random Forest, Gradient Boosting (XGBoost) o redes neuronales recurrentes (LSTM) son adecuados para este tipo de problema, ya que pueden aprender la relación entre las variables del entorno (humedad, temperatura, precipitación, etapa de crecimiento) y el comportamiento futuro del suelo. El aprendizaje no supervisado podría utilizarse de forma complementaria para identificar agrupaciones de lotes con comportamientos hídricos similares, pero no sería el enfoque principal dado que se dispone de datos históricos etiquetados con información de rendimiento y riego.

Analítica Prescriptiva: ML Supervisado + Optimización

Para la prescripción se combinaría el modelo supervisado (que estima la necesidad de riego de cada lote según humedad, temperatura, precipitación y etapa de crecimiento) con algoritmos de **optimización** que, dado el riesgo de déficit hídrico estimado y las restricciones del sistema de riego, calculan el plan óptimo para la semana. Esta combinación sigue siendo de naturaleza supervisada en su componente predictivo, ya que la optimización trabaja sobre las salidas del modelo previamente entrenado con el historial de riego y producción de la finca.

2.3 Sesgo ético identificado y estrategia de mitigación

Sesgo identificado: Sesgo por registros históricos incompletos o desiguales entre lotes

El modelo predictivo se entrena sobre el historial de datos de humedad, temperatura, consumo de agua, precipitación, etapa de crecimiento y rendimiento de cosecha. Sin embargo, en muchos entornos agroindustriales los registros son heterogéneos: algunos lotes cuentan con sensores instalados desde hace varios años y tienen historiales completos, mientras que otros son de reciente incorporación o han tenido sensores fuera de servicio durante temporadas, generando vacíos en sus registros históricos. Si el modelo se entrena con estos datos desiguales, aprenderá a predecir con mayor precisión las necesidades de los lotes mejor documentados y cometerá más errores en los lotes con datos escasos, recomendando sistemáticamente planes de riego subóptimos para estos últimos.

Adicionalmente, existe un **riesgo ético de inequidad en la asignación de recursos hídricos**: si el sistema recomienda priorizar el riego de los lotes con mejor historial de datos sin que esto corresponda a una mayor necesidad real según la humedad y la etapa de crecimiento actuales, los lotes subrepresentados pueden recibir menos agua de la requerida, afectando su rendimiento de cosecha y generando pérdidas para el productor.

Estrategia de mitigación

- **Auditoría de completitud de datos por lote:** Antes de entrenar el modelo, revisar qué proporción del historial de humedad, temperatura, consumo de agua y rendimiento de cada lote está correctamente registrada. Los lotes con datos insuficientes deben recibir



tratamiento diferenciado: umbrales de alerta más conservadores o modelos de referencia basados en lotes con suelo y cultivo similares.

- **Proceso de captura de datos estandarizado:** Implementar un protocolo obligatorio de registro que garantice que cada ciclo de riego quede documentado con fecha, volumen de agua utilizado, lote, etapa de crecimiento del cultivo y responsable, independientemente de si el sensor funcionó correctamente o no, reduciendo la tasa de registros incompletos.
- **Revisión humana de las recomendaciones:** El sistema no debe operar de forma totalmente autónoma. Los planes de riego generados por el modelo deben ser revisados por el técnico agrícola antes de ejecutarse, garantizando que la decisión final incorpore el criterio experto y no dependa exclusivamente de un algoritmo que puede tener sesgos en sus datos de entrenamiento.
- **Monitoreo continuo del modelo por lote:** Evaluar periódicamente si el modelo está cometiendo más errores de forma sistemática en ciertos lotes, lo que sería indicativo de sesgo persistente asociado a la calidad desigual de sus registros históricos y requeriría corrección o reentrenamiento diferenciado.





3. Conclusión

El ejercicio de formular una pregunta por cada tipo de analítica permite comprender que el proyecto de producción agroindustrial con gestión de riego no se agota en la descripción del consumo histórico de agua: abarca un espectro que va desde la comprensión del comportamiento pasado de las variables del caso —humedad del suelo, temperatura, precipitación, etapa de crecimiento y rendimiento de cosecha— hasta la recomendación de planes de riego óptimos adaptados a las condiciones reales de cada semana. Cada tipo de analítica aporta valor de manera distinta y, al mismo tiempo, depende de los resultados de la etapa anterior, lo que refuerza la importancia de abordar el problema de forma progresiva y estructurada.

La elección del aprendizaje automático supervisado como enfoque principal para las etapas predictiva y prescriptiva se sustenta en la disponibilidad de datos históricos etiquetados de humedad, temperatura, riego y rendimiento, que constituyen el insumo fundamental para entrenar modelos capaces de generalizar el comportamiento hídrico del cultivo hacia el futuro. Finalmente, la identificación del sesgo por registros incompletos entre lotes pone de manifiesto que los riesgos de un proyecto de ciencia de datos no son exclusivamente técnicos: la calidad de los datos y las decisiones que se toman a partir de ellos tienen implicaciones directas sobre la equidad en la asignación del agua y la rentabilidad del productor. Incorporar la dimensión ética desde el diseño del proyecto, y no como un paso posterior, es lo que distingue un análisis de datos responsable de uno meramente funcional.





4. Referencias

Food and Agriculture Organization of the United Nations. (2026). Water data and resource assessment. <https://www.fao.org/land-water/water/water-data-and-resource-assessment>

Food and Agriculture Organization of the United Nations. (2026). Tools in co-development: WaPOR, remote sensing for water productivity. <https://www.fao.org/in-action/remote-sensing-for-water-productivity/country-activities/tools-in-co-development>

IBM. (2024). What is Big Data analytics? IBM Think. <https://www.ibm.com/think/topics/big-data-analytics>

IBM. (2026). What is data velocity? IBM Think. <https://www.ibm.com/think/topics/data-velocity>

