



Actividad Práctica – Semana 4

TIPOS DE ANALÍTICA Y ÉTICA

Isabella Ramos Betancourt

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel Gonzáles Bonilla

Agosto 30 de 2026





1. Introducción

La Ciencia de Datos no se limita a describir lo que ha ocurrido en un sistema; dependiendo del tipo de pregunta que se formule y de la profundidad del análisis, es posible diagnosticar causas, anticipar eventos futuros e incluso recomendar acciones concretas. Esta progresión —de lo descriptivo a lo prescriptivo— define los cuatro tipos de analítica que estructuran el pensamiento analítico moderno y que determinan qué clase de valor puede extraerse de los datos disponibles.

En el proyecto de mantenimiento predictivo de equipos industriales, cada tipo de analítica aporta una perspectiva distinta y complementaria: desde caracterizar el historial de fallas hasta optimizar el plan de intervenciones de la semana siguiente. Este trabajo formula una pregunta representativa para cada tipo de analítica, justifica el uso de aprendizaje automático supervisado como enfoque principal para las etapas predictiva y prescriptiva, y analiza un sesgo ético concreto derivado de la incompletitud de los datos históricos, proponiendo estrategias específicas para mitigarlo. La consideración de la dimensión ética resulta indispensable en proyectos donde las recomendaciones del modelo tienen impacto directo sobre decisiones operativas y la seguridad del personal.





2. Desarrollo de la actividad

2.1. Preguntas clasificadas por tipo de analítica

A continuación se formulan cuatro preguntas sobre el caso de mantenimiento predictivo de equipos industriales, una por cada tipo de analítica.

2.1.1. Analítica Descriptiva

¿Qué ha ocurrido?

¿Cuáles equipos registraron la mayor frecuencia de fallas durante el último año y cuál fue el comportamiento promedio de sus variables operativas (temperatura, vibración, corriente) en las 48 horas previas a cada evento?

Esta pregunta busca caracterizar el historial de fallas ya ocurridas, identificar patrones de comportamiento pasado y determinar qué equipos concentran la mayor cantidad de intervenciones no programadas. Responde con estadísticas descriptivas, tablas de frecuencia y gráficas de tendencia.

2.1.1. Analítica Diagnóstica

¿Por qué ocurrió?

¿Qué combinación de variables operativas (temperatura elevada, aumento de vibración, incremento de corriente) está más asociada con las fallas registradas en los compresores de la planta?



Esta pregunta va más allá de contar fallas, puesto que busca identificar las causas raíz mediante el análisis de correlaciones entre las variables de los sensores y los eventos de falla. Permite entender por qué fallan los equipos, no solo cuándo.

2.1.1. Analítica Predictiva

¿Qué podría ocurrir?

¿Con cuántos días de anticipación puede el modelo predecir la probabilidad de falla de un equipo a partir del comportamiento actual de sus sensores de temperatura, vibración y corriente eléctrica?

Esta pregunta es el núcleo del proyecto. Busca construir un modelo que, con base en los patrones detectados en el análisis descriptivo y diagnóstico, estime la probabilidad de que un equipo falle dentro de un horizonte de tiempo determinado, de modo que el mantenimiento pueda programarse antes de que ocurra la parada.

2.2. Tipo de ML para analítica predictiva y prescriptiva

Analítica Predictiva: ML Supervisado

Para responder la pregunta predictiva se utilizaría **aprendizaje automático supervisado**. La razón es que el proyecto cuenta con un historial de fallas etiquetado: se conoce con exactitud en qué fechas ocurrieron las fallas y en qué equipos. Esto permite construir un conjunto de datos donde



cada registro de sensor tiene asociada una etiqueta (falla / no falla, o tiempo hasta la siguiente falla), que es exactamente la condición necesaria para entrenar un modelo supervisado.

Algoritmos como Random Forest, Gradient Boosting (XGBoost) o redes neuronales recurrentes (LSTM) son adecuados para este tipo de problema, ya que pueden aprender la relación entre las señales de los sensores y la ocurrencia futura de una falla (IBM, 2026).

El aprendizaje no supervisado podría utilizarse de forma complementaria para detectar anomalías en equipos sin historial de fallas suficiente, pero no sería el enfoque principal dado que se dispone de datos históricos etiquetados.

Análítica Prescriptiva: ML Supervisado + Optimización

Para la prescripción se combinaría el modelo supervisado (que estima la probabilidad de falla de cada equipo) con algoritmos de **optimización** (programación lineal o metaheurísticas) que, dado el riesgo estimado y las restricciones operativas, calculan el plan de mantenimiento óptimo. Esta combinación sigue siendo de naturaleza supervisada en su componente predictivo, ya que la optimización trabaja sobre las salidas del modelo previamente entrenado.

2.3 Sesgo ético identificado y estrategia de mitigación

Sesgo identificado: Sesgo de datos históricos incompletos

El modelo de predicción de fallas se entrena sobre el historial de fallas registradas. Sin embargo, en muchos entornos industriales los registros son incompletos: las fallas menores se resuelven sin



documentarse, los técnicos no siempre diligencian los informes de mantenimiento correctamente, y algunos equipos carecen de historial por ser de reciente instalación. Si el modelo se entrena con estos datos incompletos, aprenderá que ciertos equipos "nunca fallan" cuando en realidad simplemente no se reportaron sus fallas, lo que puede llevar a subestimar su riesgo real.

Adicionalmente, existe un riesgo ético de decisión automatizada injustificada: si el sistema recomienda priorizar el mantenimiento de ciertos equipos basándose en un modelo con sesgo, los equipos subrepresentados en los datos pueden ser sistemáticamente ignorados hasta que presenten una falla grave, con consecuencias sobre la seguridad de los trabajadores y la continuidad de la producción.

Estrategia de mitigación

- **Auditoría de completitud de datos:** Antes de entrenar el modelo, revisar qué proporción de los registros de mantenimiento está correctamente diligenciada y qué equipos presentan un historial insuficiente. Los equipos con datos escasos deben tratarse con modelos más conservadores o con umbrales de alerta más sensibles.
- **Proceso de captura de datos estandarizado:** Implementar formularios obligatorios en el sistema de gestión de mantenimiento que impidan cerrar una orden de trabajo sin registrar la causa de la falla y las acciones realizadas, reduciendo la tasa de registros incompletos hacia el futuro.



- **Revisión humana de las recomendaciones:** El sistema no debe operar de forma totalmente autónoma. Las alertas generadas por el modelo deben ser revisadas y validadas por un técnico antes de programar o postergar una intervención, garantizando que la decisión final incorpore el criterio experto y no dependa exclusivamente de un algoritmo que puede tener sesgos en sus datos de entrenamiento.
- **Monitoreo continuo del modelo:** Evaluar periódicamente el desempeño del modelo en producción para detectar si está fallando de forma sistemática en ciertos tipos de equipos, lo que sería indicativo de sesgo persistente que requiere corrección.





3. Conclusión

El ejercicio de formular una pregunta por cada tipo de analítica permite comprender que el proyecto de mantenimiento predictivo no se agota en la predicción de fallas: abarca un espectro que va desde la comprensión del comportamiento histórico de los equipos hasta la recomendación de planes de intervención concretos. Cada tipo de analítica aporta valor de manera distinta y, al mismo tiempo, depende de los resultados de la etapa anterior, lo que refuerza la importancia de abordar el problema de forma progresiva y estructurada.

La elección del aprendizaje automático supervisado como enfoque principal para las etapas predictiva y prescriptiva se sustenta en la disponibilidad de datos históricos etiquetados, que constituyen el insumo fundamental para entrenar modelos capaces de generalizar el comportamiento de los equipos hacia el futuro. Finalmente, la identificación del sesgo por registros incompletos pone de manifiesto que los riesgos de un proyecto de ciencia de datos no son exclusivamente técnicos: la calidad de los datos y las decisiones que se toman a partir de ellos tienen implicaciones directas sobre la seguridad de los trabajadores y la equidad en la asignación de recursos de mantenimiento. Incorporar la dimensión ética desde el diseño del proyecto, y no como un paso posterior, es lo que distingue un análisis de datos responsable de uno meramente funcional.





4. Referencias

IBM. (2026). *¿Qué es el mantenimiento predictivo?* IBM Think. <https://www.ibm.com/es-es/think/topics/predictive-maintenance>

IBM. (2026). *The role of AI in predictive maintenance.* IBM Think. <https://www.ibm.com/think/insights/ai-in-predictive-maintenance>

NIST. (2018). *A data processing pipeline for prediction of milling machine tool condition from raw sensor data.* National Institute of Standards and Technology. <https://www.nist.gov/publications/data-processing-pipeline-prediction-milling-machine-tool-condition-raw-sensor-data>

